

УДК 336.77

*Девайкина Анастасия Сергеевна**аспирант,**кафедра применения математических методов в экономике,**Новосибирский государственный университет,**г. Новосибирск, Российская Федерация,**e-mail: a.devaikina@g.nsu.ru*

РАЗРАБОТКА МОДЕЛИ ДОЛИ ПОТЕРЬ ПРИ ДЕФОЛТЕ (LGD) ДЛЯ ОЦЕНКИ КРЕДИТНОГО РИСКА КОММЕРЧЕСКОГО БАНКА

Аннотация. Моделирование доли потерь при дефолте (LGD) представляет собой одну из наиболее сложных методологических задач в рамках оценки кредитного риска. Это связано с особенностями эмпирического распределения и необходимостью соблюдения требований к интерпретируемости модели. В данной работе рассматривается возможность построения прозрачной модели, которая по качеству прогнозов способна конкурировать с алгоритмами класса «черный ящик». Представлен модульный подход, основанный на разбиении диапазона значений LGD и обучении специализированных моделей на подвыборках, соответствующих различным участкам распределения. Подход опробован на данных по автокредитам одного из коммерческих банков РФ.

Ключевые слова: кредитный риск, доля потерь при дефолте (LGD), интерпретируемая модель, U-образное распределение, гибридный подход.

*Anastasia S. Devaikina**PhD Student,**Department for Application of Mathematical Methods in Economics,**Novosibirsk State University,**Novosibirsk, Russian Federation,**e-mail: a.devaikina@g.nsu.ru*

DEVELOPMENT OF A LOSS GIVEN DEFAULT (LGD) MODEL FOR THE CREDIT RISK ASSESSMENT OF A COMMERCIAL BANK

Abstract. Modeling Loss Given Default (LGD) is one of the most complex methodological challenges in credit risk analysis. This complexity arises from the empirical distribution's characteristics and the regulatory requirement for model transparency. The paper explores the development of an interpretable LGD model that can deliver predictive quality comparable to black-box algorithms. A modular approach is introduced, which partitions the LGD range and trains specialized models on data subsets corresponding to different regions of the distribution. The methodology is illustrated using a dataset of auto loan defaults from a Russian commercial bank.

Keywords: credit risk, loss given default (LGD), interpretable model, U-shaped distribution, hybrid approach.

Статья публикуется по итогам Всероссийской студенческой научно-практической конференции «Аюшиевские чтения. Финансовая наука, практика, образование: от истоков до современности», Байкальский государственный университет, 14 мая 2025 г., г. Иркутск.

Центральный Банк РФ в 2025 опубликовал Положение № 845-П о порядке расчета величины кредитного риска. Согласно документу, банки, признанные системно значимыми, обязаны к 2030 году обеспечить внутреннюю модельную оценку для как минимум половины кредитных требований [1]. Для выполнения данной нормы банковским организациям необходимо разработать и внедрить собственные модели оценки компонентов кредитного риска.

Одним из основных требований к моделям оценки кредитного риска для формирования резервов и оценки достаточности капитала является их интерпретируемость. Это в свою очередь может затруднять достижение высокой точности, дискриминационной способности и стабильности моделей [2].

Таким образом, разработка и внедрение собственных надежных, хорошо интерпретируемых моделей для управления кредитным риском – актуальная задача для российских банков.

В рамках данной работы рассматривается компонент кредитного риска – Доля потерь при дефолте (LGD), который считается одним из самых сложных для моделирования, поскольку характеризуется бимодальностью и асимметрией распределения, а также ограничением значений в интервале $[0; 100 \ %]$ [3]. Целью исследования является разработка модели LGD, которая сочетает в себе интерпретируемую структуру и достаточную прогностическую силу.

Данные для исследования сформированы на основе портфеля по дефолтным автокредитам коммерческого банка РФ за 2019–2024 годы. Каждый случай дефолта реплицирован по срезам вплоть до 12 месяцев от даты начала дефолта. В результате сформирована выборка разработки свыше 500 тыс. наблюдений. В качестве признаков использовались сведения о заемщике, параметры договора и залога, кредитная история и макроэкономические индикаторы.

Целевая переменная (LGD) рассчитана с учетом дисконтированных денежных потоков по дефолтной ссуде за период от даты начала до даты окончания дефолта. Для незавершенных дефолтов применяется техника калибровки с использованием 97-процентного перцентиля как точки горизонта эффективного сбора платежей, за пределами которого вероятность поступлений незначительна.

Учитывая распределение значений LGD с пиками в краевых зонах, предлагается построение составной модульной модели с разбиением выборки на три сегмента: низкие потери, средние и высокие.

1) **Модуль Class_0** идентифицирует случаи с низкими потерями, где LGD определен вблизи нуля.

2) **Модуль Class_1** – вблизи единицы.

3) **Модуль Central** применяется к промежуточным значениям LGD.

Конечная оценка LGD формируется на основе вероятностного выбора между модулями и значений регрессионного прогноза по Формуле:

$$LGD_pred_i = \begin{cases} \mu_0, & \text{если } p_0 > 0.5 \text{ и } p_0 > p_1 + 0.1 \\ \mu_1, & \text{если } p_1 > 0.5 \text{ и } p_1 > p_0 + 0.1, \\ y_{central}, & \text{иначе} \end{cases} \quad (1)$$

Где LGD_pred_i – прогнозное значение LGD после объединения модулей; p_0 – вероятность модуля **Class_0**, что наблюдение относится к области низких значений LGD; p_1 – вероятность модуля **Class_1**, что наблюдение относится к области высоких значений LGD; μ_0 – среднее фактическое LGD в области низких значений LGD; μ_1 – среднее фактическое LGD в области высоких значений LGD; $y_{central}$ – прогнозное значение LGD модуля **Central**.

Для определения диапазонов модулей используется нормированный на ширину интервала модифицированный индекс Херфиндаля-Хиршмана. Этот показатель позволяет оценить уровень концентрации наблюдений в пределах каждого потенциального диапазона значений LGD. Минимизация показателя позволяет выделить максимально равномерную и вместе с тем широкую центральную зону LGD между двумя областями высокой плотности: $LGD \leq 22\%$ и $LGD > 88\%$. На рис. 1 представлено распределение LGD при оптимизированных границах.




Рис. 1. Распределение фактических LGD при оптимизированных границах

Для модулей **Class_0** и **Class_1** были протестированы различные модели бинарной классификации. Лучшие показатели достигнуты при использовании деревьев решений. Для модуля **Central** на диапазоне оптимальных границ отсечения LGD (0.22; 0.88) были протестированы регрессионные методы, наилучший результат показало дерево регрессии. В качестве **бенчмарка** рассмотрена модель

случайного леса, которая традиционно демонстрирует высокую эффективность в задачах прогноза LGD [4; 5; 6].

В дереве модуля **Class_0** на назначение класса потерь в диапазоне [0; 0.22] влияют следующие ключевые моменты:

1) Если клиент ранее успешно закрывал кредиты с просрочкой, это может трактоваться как сигнал об ответственности и способности восстановить платежную дисциплину в кризисные моменты. Такой опыт делает более вероятными невысокие потери в случае выхода в дефолт.

2) Отсутствие просрочек по действующим займам на поздней стадии погашения (когда оставшийся срок кредитного договора менее 4 лет) сокращает риск ухудшения платежеспособности и указывает на невысокие потери при дефолте.

3) Низкий пробег транспортного средства свидетельствует о высокой ликвидности залога и большей вероятности покрытия долга при реализации залога, что способствует более низкому LGD.

В дереве модуля **Class_1** на назначение класса высоких потерь в диапазоне [0.88; 1] влияют следующие обстоятельства:

1) Если заемщик не имеет подтвержденного опыта успешного закрытия просроченных кредитов, то предсказуемость его поведения в условиях кризиса ниже, что увеличивает риски и вероятность высоких потерь при дефолте.

2) Наличие активной просрочки является тревожным индикатором, указывает на нестабильное финансовое положение и возможные большие трудности при взыскании.

3) Если много времени остается до окончания договора клиента (более четырех лет), то повышается непредсказуемость поведения клиента, что негативно влияет на величину LGD.

Ключевым узлом дерева модуля **Central** является доля просрочек среди всех кредитов клиента. При ее низком уровне ожидаются относительно низкие потери, особенно при невысоких сроках до планового закрытия и малом пробеге транспортного средства, а также доходе выше 112 тыс. руб. При увеличении срока кредита или пробега риск потерь растет. В случаях с более высокими значениями доли просрочек по кредитам, влияние начинают оказывать такие факторы, как смена имени, занятость, возраст, долг и доля платежей последнего года к общему долгу. Например, у молодых клиентов с низким долгом и сменой имени ожидаются повышенные значения доли потерь при дефолте.

Прогнозные распределения модульной модели и бенчмарка представлены на рис. 2. Модульная модель обеспечила более реалистичное распределение прогнозов, но при этом перенасытила крайний диапазон высоких потерь. Случайный лес продемонстрировал более точечные прогнозы в центральной части, но не смог идентифицировать крайнюю зону высоких потерь, что критически важно для оценки кредитного риска.




Рис. 2. Распределение прогнозных оценок LGD модульной модели и модели случайного леса при выбранных границах на тестовой выборке

Метрики качества модульной модели и бенчмарка на тестовой выборке представлены в табл. 1. Модульная модель демонстрирует конкурентоспособную точность (MAE и MAD) и большую консервативность оценки потерь (Loss Shortfall). Модель случайного леса лучше справляется с ранжированием LGD (SomersD и корреляция Спирмена), но делает это ценой утраты интерпретируемости и искажения формы распределения.

Таблица 1

Метрики оценки качества модульной модели и модели случайного леса

Модель	SomersD	Spearman correlation	MAE	MAD	Loss Shortfall
Модульная модель	0.39	0.59	0.26	0.26	-0.17
Случайный лес	0.50	0.66	0.26	0.27	0.01

Таким образом, разработанный подход демонстрирует, что возможно построение гибридной модульной модели LGD для U-образной формы распределения, которая сохраняет прозрачность логики оценивания, соответствует требованиям нормативного регулирования и при этом обеспечивает достаточное качество прогнозов.

Список использованной литературы

1. О порядке расчета величины кредитного риска банками с применением банковских методик управления кредитным риском и моделей количественной оценки кредитного риска: Положение Банка России от 02.11.2024 №845-П.
2. Baesens B. Boosting credit risk models / B. Baesens, K. Smedts. – DOI 10.1016/j.bar.2023.101241 // The British Accounting Review. – 2023.

3. Loterman G. Benchmarking regression algorithms for loss given default modeling / G. Loterman, I. Brown, D. Martens, C. Mues, B. Baesens. – DOI 10.1016/j.ijforecast.2011.01.006 // International Journal of Forecasting. – 2012. – Vol. 28. – P. 161–170.
4. Bellotti A. Forecasting recovery rates on non-performing loans with machine learning / A. Bellotti, D. Brigo, P. Gambetti, F. Vrins. – DOI 10.1016/j.ijforecast.2020.06.009 // International Journal of Forecasting. – 2020.
5. Kaposty F. Predicting loss given default in leasing: A closer look at models and variable selection / F. Kaposty, J. Kriebel, M. Loderbusch. – DOI 10.1016/j.ijforecast.2019.05.009 // International Journal of Forecasting. – 2019.
6. Miller P. Loss Given Default Adjusted Workout Processes for Leases / P. Miller, E. Tows. – DOI 10.1016/j.jbankfin.2017.01.020 // Journal of Banking and Finance. – 2017.